

Báo cáo Tổng hợp ASR Lâm sàng (Tuần 3)

Benchmark, Tiền xử lý Âm thanh và Chuẩn bị Fine-tuning
Dự án: Local-first Clinical Ambient Documentation Assistant for Vietnamese
Outpatient Care

Vũ Đức Duy

Ngày lập: 09/06/2026

Tóm tắt nội dung

Báo cáo này tổng hợp toàn diện kết quả của giai đoạn đánh giá mô hình ASR (Benchmark) và thực nghiệm tiền xử lý âm thanh (Ablation Study) cho dữ liệu y khoa tiếng Việt.

Phần thứ nhất trình bày kết quả so sánh các mô hình ASR, trong đó `khanhld/chunkformer-ctc-large` đạt độ chính xác tốt nhất (WER 12.90%), cùng các phân tích chuyên sâu về rủi ro lâm sàng như sai phủ định và thiếu sót triệu chứng. Phần thứ hai phân tích vấn đề "Edge Loss" (mất từ ở biên) và chứng minh hiệu quả của kỹ thuật VAD + Padding 200ms trong việc bảo vệ tín hiệu.

Cuối cùng, báo cáo cập nhật các kết quả kiểm tra thủ công mới nhất dẫn đến quyết định áp dụng chiến lược "Safe Hybrid", tiêu chuẩn hóa quy trình Benchmark End-to-End, và xác nhận mức độ sẵn sàng cho giai đoạn Fine-tuning sắp tới.

Mục lục

PHẦN I: BÁO CÁO BENCHMARK VÀ LỖI LÂM SÀNG	4
1 Tóm tắt Điều hành	4
1.1 Mục tiêu báo cáo	4
1.2 Kết luận nổi bật	4
1.3 Thông điệp chính	4
2 Bối cảnh & Mục tiêu Đánh giá	4
2.1 Bối cảnh dự án	4
2.2 Mục tiêu định lượng	5
2.3 Phạm vi đánh giá	5
3 Dữ liệu, Chia tập và Kiểm soát Benchmark	6
3.1 Nguồn dữ liệu	6
3.2 Chiến lược chia tập	6
3.3 Kiểm tra rò rỉ dữ liệu	6
3.4 Kiểm soát tính tái lập	6

4	Giao thức Đo lường	7
4.1	Các chỉ số chính	7
4.2	Chuẩn hóa transcript	7
4.3	Giới hạn của WER trong y tế	7
5	Các Mô hình được Đánh giá	8
6	Kết quả Benchmark	8
6.1	Bảng kết quả tổng hợp	8
6.2	Biểu đồ Normalized WER	8
6.3	Nhận định từ kết quả	9
7	Phân tích Lỗi Lâm sàng	9
7.1	Taxonomy lỗi y khoa	9
7.2	Kết quả lỗi y khoa mở rộng	9
7.3	Ý nghĩa an toàn	10
7.4	Ví dụ lỗi nguy hiểm	10
8	Đánh đổi Tốc độ và Độ chính xác	10
8.1	So sánh thực tiễn	10
8.2	Ma trận khuyến nghị theo kịch bản	10
9	Quyết định Mô hình và Kế hoạch Tiếp theo	11
9.1	Quyết định mô hình	11
9.2	Kế hoạch hành động ngay	12
9.3	Chiến lược tuần 4	12
10	Rủi ro, Giới hạn và Biện pháp Giảm thiểu	12
10.1	Rủi ro chính	12
10.2	Giới hạn của báo cáo	13
11	Kết luận	13
12	Phụ lục — Giả định	13

PHẦN II: BÁO CÁO KỸ THUẬT TIỀN XỬ LÝ ÂM THANH

14

1	Tóm tắt Điều hành	14
1.1	Mục tiêu báo cáo	14
1.2	Kết luận nổi bật	14
2	Hiện trạng Chất lượng Âm thanh và Lỗi Edge Loss	14
2.1	Khảo sát chất lượng ban đầu (Audio QA)	14
2.2	Tình trạng Âm lượng (Loudness)	15
2.3	Chuẩn hóa Định dạng Âm thanh (16kHz Mono PCM)	15

3	Đánh giá Thực nghiệm Tiền xử lý (Ablation Study)	15
3.1	Định nghĩa các biến thể (Preprocessing Variants)	15
3.2	Kết quả Leaderboard (Tập Dev)	15
3.3	Nhận định Thành tựu	15
4	Chiến lược Lựa chọn Mô hình Thực nghiệm	16
4.1	Danh mục các mô hình hiện có	16
4.2	Lý do chỉ dùng ChunkFormer cho Ablation Study	16
5	Lý luận Kỹ thuật: Các Phương án Bị Loại bỏ	17
6	Kết luận	17

PHẦN III: CÁC CẬP NHẬT MỚI VÀ SẴN SÀNG FINE-TUNING 18

1	Đánh giá Thủ công (Manual Inspection) và Chiến lược Safe Hybrid	18
1.1	Phát hiện rủi ro từ VAD	18
1.2	Chiến lược Safe Hybrid (p03_safe_hybrid_v0_1)	18
2	Chuẩn hóa Quy trình End-to-End và Tái Cấu trúc Dự án	19
2.1	Tài liệu hóa 10-step ASR Benchmark Pipeline	19
2.2	Tái cấu trúc thư mục Notebooks	19
3	Sẵn sàng cho Giai đoạn Fine-tuning	19

PHẦN I: BÁO CÁO BENCHMARK VÀ LỖI LÂM SÀNG

1 Tóm tắt Điều hành

1.1 Mục tiêu báo cáo

Báo cáo này được xây dựng nhằm phục vụ trao đổi kỹ thuật với mentor/sếp về kết quả đánh giá ASR trong dự án *Clinical Ambient Documentation Assistant*. Trọng tâm không chỉ là so sánh WER giữa các mô hình, mà còn đánh giá khả năng sử dụng trong một pipeline y tế có yêu cầu truy vết, an toàn và human-in-the-loop.

Các mục tiêu chính gồm:

- So sánh các mô hình ASR tiếng Việt/y khoa trên cùng một tập phát triển VietMed.
- Đo Strict WER, Normalized WER, Strict CER và Normalized CER bằng cùng một giao thức chuẩn hóa.
- Phân tích các lỗi lâm sàng có rủi ro cao: phủ định, triệu chứng, thuốc, liều/đơn vị, dị ứng và red flag.
- Đề xuất mô hình primary, mô hình backup và kế hoạch fine-tuning cho tuần tiếp theo.

1.2 Kết luận nổi bật

1.3 Thông điệp chính

Kết quả $WER < 20\%$ là điều kiện kỹ thuật cần, nhưng chưa đủ cho hệ thống ghi chép lâm sàng. Một mô hình có WER thấp vẫn có thể không an toàn nếu bỏ sót các từ khóa như “không”, “chưa”, “dị ứng”, “đau ngực”, “khó thở” hoặc sai liều lượng thuốc. Vì vậy, kết quả tuần này nên được hiểu theo hai lớp:

1. **Lớp ASR Accuracy:** ChunkFormer hiện là mô hình đạt độ chính xác tổng quát tốt nhất.
2. **Lớp Clinical Safety:** Cần có hậu kiểm bằng từ điển y khoa, kiểm tra phủ định, kiểm tra số/liều và review của bác sĩ trước khi dùng trong ghi chú lâm sàng.

2 Bối cảnh & Mục tiêu Đánh giá

2.1 Bối cảnh dự án

Dự án hướng đến một trợ lý ghi chép lâm sàng chạy theo định hướng local-first cho bối cảnh khám ngoại trú tiếng Việt. Hệ thống nhận audio cuộc khám, tạo transcript, phân đoạn người nói, trích xuất clinical facts có nguồn dẫn, tạo SOAP-lite draft và đưa cho bác sĩ xác nhận trước khi dữ liệu trở thành bản ghi có giá trị sử dụng.

Bảng 1: Tóm tắt kết quả điều hành

Hạng mục	Kết luận
Mô hình chính xác nhất	khanhld/ chunkformer-ctc-large-vie, đạt WER 12.90%, vượt mục tiêu < 20%.
Mô hình thực tiễn nhất	vinai/ PhoWhisper-medium, đạt Normalized WER 21.51%, runtime khoảng 0.42 giây/mẫu.
Mô hình nhẹ nhất	vinai/ PhoWhisper-base, runtime khoảng 0.14 giây/mẫu nhưng WER còn cao hơn medium.
Mô hình bị loại khỏi hướng chính	openai/ whisper-small, Normalized WER 53.23%, không cạnh tranh trên tiếng Việt y khoa trong thử nghiệm này.
Rủi ro lâm sàng chính	Tất cả mô hình đều còn lỗi bỏ sót phủ định và triệu chứng; đây là nhóm lỗi có thể đảo nghĩa lâm sàng.
Khuyến nghị trước mắt	Chạy ChunkFormer trên test_holdout đúng một lần, đồng thời chuẩn bị fine-tuning PhoWhisper-medium và xây tầng kiểm tra an toàn hậu ASR.

Trong pipeline này, ASR là tầng đầu tiên. Nếu ASR sai, các tầng phía sau như diarization, clinical fact extraction, source attribution và SOAP note generation đều có nguy cơ sai dây chuyền. Vì vậy, benchmark ASR phải được đánh giá không chỉ bằng WER/CER mà còn bằng lỗi lâm sàng.

2.2 Mục tiêu định lượng

Mục tiêu định lượng được đặt ra cho giai đoạn này:

- Đạt WER < 20% trên dữ liệu tiếng Việt y khoa.
- Có benchmark tái lập trên cùng một split.
- Không sử dụng test_holdout để chọn mô hình.
- Ghi nhận và phân tích các lỗi y khoa quan trọng.

Baseline tham chiếu do mentor/sếp cung cấp là Whisper-small fine-tuned trên VietMed với WER khoảng 31%. Do đó, mô hình được chọn cần cải thiện rõ ràng so với mốc này.

2.3 Phạm vi đánh giá

Phạm vi của báo cáo này bao gồm:

- Benchmark trên tập dev VietMed gồm 200 mẫu.
- So sánh bốn mô hình: ChunkFormer, PhoWhisper-medium, PhoWhisper-base và Whisper-small.

- Phân tích tốc độ suy luận và lỗi y khoa.
- Đưa ra quyết định mô hình cho test_holdout và kế hoạch fine-tuning tuần 4.

Báo cáo này chưa bao gồm đánh giá trên dữ liệu bệnh nhân thật, chưa đánh giá full outpatient encounter audio, và chưa đánh giá diarization.

3 Dữ liệu, Chia tập và Kiểm soát Benchmark

3.1 Nguồn dữ liệu

Dữ liệu đánh giá chính là VietMed, một nguồn speech y khoa tiếng Việt được sử dụng trong dự án cho mục tiêu benchmark ASR. Trong quá trình thực nghiệm, dữ liệu được đưa vào data lake theo kiến trúc Bronze/Silver/Evaluation:

- **Bronze:** Raw audio, raw transcript, metadata, license snapshot và checksum.
- **Silver:** Audio đã chuẩn hóa 16kHz mono WAV, manifest ASR, duration và checksum.
- **Evaluation:** test_holdout cố định, không dùng để huấn luyện hoặc chọn checkpoint.

3.2 Chiến lược chia tập

Tập VietMed sau khi ingest và chuẩn hóa được chia thành ba phần:

Bảng 2: Chiến lược chia tập VietMed


Split	Số mẫu	Mục đích sử dụng
train_candidate	600	Dùng cho fine-tuning nội bộ, không dùng để báo cáo kết quả cuối.
dev	200	Dùng cho model selection, so sánh baseline và chọn checkpoint.
test_holdout	200	Chỉ dùng để xác nhận cuối cùng, không dùng để chọn mô hình.

3.3 Kiểm tra rò rỉ dữ liệu

Benchmark chỉ có ý nghĩa khi không có rò rỉ giữa train/dev/test. Theo báo cáo tuần 3, leakage check đạt trạng thái PASS: không có trùng lặp `sample_id` giữa ba tập. Đây là điều kiện quan trọng để tránh tình trạng metric ảo.

3.4 Kiểm soát tính tái lập

ChunkFormer đã được chạy lại độc lập trên 200 mẫu dev và kết quả WER khớp chính xác với lần chạy trước. Điều này cho thấy pipeline inference, manifest, text normalization và script tính metric có tính ổn định đủ để tiếp tục dùng làm benchmark trong tuần 4.



Hình 1: Luồng dữ liệu ASR từ Bronze/Silver đến benchmark và quyết định mô hình

4 Giao thức Đo lường

4.1 Các chỉ số chính

Báo cáo sử dụng bốn chỉ số:

1. **Strict WER:** So sánh reference và prediction ở dạng nguyên bản.
2. **Normalized WER:** So sánh sau chuẩn hóa text.
3. **Strict CER:** Character Error Rate nguyên bản.
4. **Normalized CER:** Character Error Rate sau chuẩn hóa.

Trong bối cảnh tiếng Việt y khoa, Normalized WER đặc biệt quan trọng vì transcript có thể biểu diễn số và đơn vị theo nhiều cách khác nhau, ví dụ “năm trăm miligam” và “500 mg”.

4.2 Chuẩn hóa transcript

Text normalization áp dụng các bước:

- Chuyển lowercase.
- Chuẩn hóa Unicode NFC.
- Loại bỏ dấu câu không có giá trị y khoa.
- Chuẩn hóa khoảng trắng.
- Chuẩn hóa một số biểu diễn y khoa như đơn vị và số: năm trăm miligam → 500 mg, ba mươi bảy độ tám → 37.8 độ.

Điểm quan trọng là cùng một script chuẩn hóa được áp dụng cho mọi mô hình, bảo đảm tính công bằng trong so sánh.

4.3 Giới hạn của WER trong y tế

WER là chỉ số cần thiết nhưng không đủ. Hai transcript có cùng WER có thể có mức rủi ro lâm sàng rất khác nhau. Ví dụ:

- Mất từ “không” trong câu “không đau ngực” có thể đảo nghĩa lâm sàng.
- Sai “500 mg” thành “50 mg” có thể ảnh hưởng nghiêm trọng đến ghi nhận thuốc.
- Sai tên bệnh như “parkinson” thành cụm từ vô nghĩa làm mất thông tin chẩn đoán.

Vì vậy, báo cáo bổ sung phân tích lỗi y khoa theo nhóm rủi ro.

5 Các Mô hình được Đánh giá

Bảng 3: Tổng quan các mô hình ASR được đánh giá

Mô hình	Kiến trúc	Điểm mạnh	Điểm yếu / Lưu ý
chunkformer-ctc-large-vie	CTC / ChunkFormer	WER thấp nhất; phù hợp làm accuracy benchmark.	Runtime chậm hơn; cần pipeline CTC riêng; cần rà soát license nếu dùng ngoài nội bộ.
PhoWhisper-medium	Seq2Seq / Whisper	Cân bằng tốc độ và chất lượng; phù hợp fine-tuning; runtime tốt.	Zero-shot chưa đạt WER < 20%; cần fine-tuning và safety layer.
PhoWhisper-base	Seq2Seq / Whisper	Rất nhanh; phù hợp phương án edge hoặc máy yếu.	WER cao hơn medium; cần đánh đổi chất lượng.
whisper-small	Seq2Seq / Whisper	Baseline quốc tế, dễ chạy.	WER quá cao trong thử nghiệm này; không phù hợp làm hướng chính.


6 Kết quả Benchmark

6.1 Bảng kết quả tổng hợp

Bảng 4: Kết quả benchmark trên tập dev VietMed 200 mẫu

Rank	Mô hình	Strict WER	Norm. WER	Strict CER	Norm. CER	Runtime
1	khanhld/chunkformer-ctc-large-vie	12.90%	12.90%	12.03%	12.03%	~1.23s/mẫu
2	vinai/PhoWhisper-medium	24.64%	21.51%	19.83%	19.54%	~0.42s/mẫu
3	vinai/PhoWhisper-base	26.75%	24.11%	21.05%	20.73%	~0.14s/mẫu
4	openai/whisper-small	58.58%	53.23%	46.69%	44.85%	~0.26s/mẫu

6.2 Biểu đồ Normalized WER



Hình 2: So sánh Normalized WER giữa các mô hình ASR

6.3 Nhận định từ kết quả

- **ChunkFormer** là mô hình duy nhất đạt mục tiêu WER < 20% trên tập dev. Đây là benchmark độ chính xác tốt nhất hiện tại.
- **PhoWhisper-medium** chưa đạt ngưỡng < 20% ở trạng thái zero-shot, nhưng gần mục tiêu và có tốc độ nhanh hơn đáng kể.
- **PhoWhisper-base** là phương án nhẹ, hữu ích cho edge deployment hoặc máy cấu hình thấp, nhưng cần cải thiện thêm.
- **Whisper-small** không phù hợp làm hướng chính cho tiếng Việt y khoa trong thử nghiệm này.

7 Phân tích Lỗi Lâm sàng

7.1 Taxonomy lỗi y khoa

Bên cạnh WER/CER, hệ thống phân tích sáu nhóm lỗi có ý nghĩa lâm sàng:

Bảng 5: Phân loại lỗi ASR có rủi ro y khoa

Nhóm lỗi	Mức rủi ro	Ý nghĩa
Negation	Critical	Bỏ sót hoặc ảo giác từ phủ định có thể đảo nghĩa lâm sàng, ví dụ “không đau” thành “đau”.
Allergy	Critical	Sai hoặc bỏ sót dị ứng có thể gây rủi ro điều trị nghiêm trọng.
Medication	High	Sai tên thuốc ảnh hưởng trực tiếp đến ghi chép điều trị.
Dose/Unit	High	Sai liều hoặc đơn vị có thể gây sai lệch 10 lần hoặc hơn.
Symptom	High	Bỏ sót triệu chứng làm thiếu thông tin chẩn đoán.
Red flag	High	Bỏ sót đau ngực, khó thở, sốt cao hoặc dấu hiệu nguy hiểm làm giảm khả năng phát hiện tình huống cần tái khám/ưu tiên.

7.2 Kết quả lỗi y khoa mở rộng

Bảng 6: Lỗi y khoa trên tập dev, bao gồm ChunkFormer

Mô hình	Phủ định miss	Triệu chứng miss	Thuốc miss	Liều/đơn vị miss	Dị ứng miss	Red flag miss	Mẫu Critical/High
ChunkFormer	7	7	0	1	0	0	7
PhoWhisper-medium	7	7	0	1	0	0	7
PhoWhisper-base	6	9	0	1	0	0	6

7.3 Ý nghĩa an toàn

Kết quả trên cho thấy WER thấp không đồng nghĩa với không có lỗi lâm sàng. ChunkFormer có WER tốt nhất, nhưng số mẫu có lỗi Critical/High vẫn tương đương PhoWhisper-medium. Do đó, mô hình ASR không nên được xem là nguồn sự thật cuối cùng. Transcript phải tiếp tục đi qua:

- kiểm tra phở định;
- kiểm tra thuật ngữ y khoa;
- kiểm tra thuốc/liều/đơn vị;
- kiểm tra red flag;
- source attribution;
- review của bác sĩ.

7.4 Ví dụ lỗi nguy hiểm

Bảng 7: Ví dụ lỗi lâm sàng từ manual audit

Loại lỗi	Reference	Prediction	Rủi ro
Bỏ sót phở định	ta không nên sờ nắn bóp vào đây	ta nên sờ nắn bóp vào đây	Đảo nghĩa khuyến cáo y khoa
Bỏ sót phở định	đau đớn thế nào thì bây giờ nó không	mất từ “không”	Đảo nghĩa tình trạng đau
Ảo giác phở định	với cột sống ngực đau bởi vì	không phải là cổ sống lưng	Tự thêm phở định, làm sai nghĩa
Sai thuật ngữ bệnh	người bệnh parkinson	người bệnh bạc kinh doanh	Mất thông tin bệnh lý

8 Đánh đổi Tốc độ và Độ chính xác

8.1 So sánh thực tiễn

8.2 Ma trận khuyến nghị theo kịch bản

Bảng 8: Đánh đổi giữa Normalized WER và Runtime

Mô hình	Norm. WER	Runtime	Phù hợp cho
ChunkFormer	12.90%	~1.23s/mẫu	Offline batch, accuracy benchmark, safety-critical transcription có hậu kiểm.
PhoWhisper-medium	21.51%	~0.42s/mẫu	Interactive assistant, candidate fine-tuning, near-real-time.
PhoWhisper-base	24.11%	~0.14s/mẫu	Edge/mobile hoặc máy yếu, chấp nhận WER cao hơn.

Bảng 9: Khuyến nghị mô hình theo kịch bản sử dụng

Kịch bản	Mô hình khuyến nghị	Lý do
Batch transcription/offline	ChunkFormer	Chính xác nhất, runtime chậm hơn nhưng vẫn chấp nhận được nếu không cần realtime.
Interactive clinical assistant	PhoWhisper-medium sau fine-tuning	Tốc độ tốt hơn ChunkFormer, có khả năng đạt target sau adaptation.
Edge hoặc thiết bị hạn chế tài nguyên	PhoWhisper-base	Runtime thấp nhất, phù hợp thử nghiệm thiết bị cấu hình thấp.
Safety-critical documentation	ChunkFormer + HITL review	WER thấp nhất nhưng vẫn phải có bác sĩ kiểm tra.
Fine-tuning tuần 4	PhoWhisper-medium	Cân bằng tốc độ-chất lượng, kiến trúc Seq2Seq thuận lợi cho adaptation.

9 Quyết định Mô hình và Kế hoạch Tiếp theo

9.1 Quyết định mô hình

Bảng 10: Quyết định mô hình sau benchmark

Vai trò	Mô hình / Quyết định
Primary accuracy benchmark	kanhld/chunkformer-ctc-large-vie
Candidate fine-tuning	vinai/PhoWhisper-medium
Fallback edge candidate	vinai/PhoWhisper-base
Model bị loại khỏi hướng chính	openai/whisper-small

9.2 Kế hoạch hành động ngay

1. Chạy ChunkFormer trên `test_holdout` đúng một lần duy nhất để xác nhận kết quả ngoài dev.
2. Tính Strict WER, Normalized WER, Strict CER, Normalized CER trên `test_holdout`.
3. Chạy phân tích lỗi y khoa trên kết quả test.
4. Chuẩn bị fine-tuning PhoWhisper-medium trong tuần 4.
5. Xây tầng post-ASR clinical safety checker cho phủ định, thuốc/liều, dị ứng và red flag.
6. Bảo toàn `test_holdout`: không dùng để chọn mô hình hoặc điều chỉnh normalization.

9.3 Chiến lược tuần 4

Tuần 4 nên tập trung vào hai nhánh:

- **Nhánh 1 – Xác nhận ChunkFormer:** Chạy `test_holdout` và lập model card cho mô hình primary.
- **Nhánh 2 – Fine-tuning PhoWhisper-medium:** Dùng `train_candidate` 600 mẫu, dev 200 mẫu để giảm Normalized WER và giảm lỗi phủ định/thuốc/liều.

Nếu PhoWhisper-medium sau fine-tuning đạt $WER < 20\%$ và có lỗi y khoa không tệ hơn ChunkFormer, mô hình này có thể trở thành lựa chọn thực tiễn cho interactive assistant nhờ runtime tốt hơn.

10 Rủi ro, Giới hạn và Biện pháp Giảm thiểu

10.1 Rủi ro chính

Bảng 11: Rủi ro còn lại sau benchmark ASR

Rủi ro	Tác động	Biện pháp giảm thiểu
Bỏ sót phủ định	Đảo nghĩa lâm sàng, ví dụ không đau thành đau.	Negation checker, highlight trong UI, bác sĩ xác nhận.
Sai thuật ngữ bệnh/triệu chứng	Mất thông tin lâm sàng quan trọng.	Từ điển y khoa, keyword recall, post-ASR flagging.
Sai thuốc/liều/đơn vị	Có thể ảnh hưởng nội dung ghi nhận điều trị.	Regex số/liều, double-check UI, cảnh báo bắt buộc.
WER thấp nhưng safety chưa đạt	Metric kỹ thuật gây cảm giác an toàn giả.	Báo cáo song song WER và clinical error metrics.
Test leakage	Làm kết quả benchmark mất giá trị.	Test chỉ chạy cho selected model, không dùng test để chọn checkpoint.

Rủi ro	Tác động	Biện pháp giảm thiểu
Domain gap	VietMed chưa đại diện đầy đủ outpatient encounter thật.	Tạo volunteer/actor data và synthetic audio ở các tuần sau.
License/deployment risk	Một số model có thể không phù hợp thương mại.	Rà soát license trước pilot/commercial.

10.2 Giới hạn của báo cáo

- Benchmark hiện dựa trên tập dev VietMed, chưa phải test_holdout cuối cùng.
- Chưa có dữ liệu bệnh nhân thật và chưa đánh giá trong điều kiện phòng khám thật.
- Chưa đánh giá diarization, speaker role và clinical attribution trên audio thật.
- Synthetic outpatient cases hiện phục vụ downstream clinical NLP và safety seed, chưa thay thế được medical speech benchmark.

11 Kết luận

Kết quả benchmark cho thấy bài toán đạt WER < 20% là khả thi với mô hình `khanhld/chunkformer-ct` khi mô hình này đạt 12.90% trên tập dev VietMed 200 mẫu. Tuy nhiên, yêu cầu của hệ thống ghi chép lâm sàng không dừng ở WER. Lỗi phủ định, lỗi triệu chứng, lỗi thuốc/liều và lỗi dị ứng vẫn phải được xem là rủi ro cấp cao.

Khuyến nghị triển khai là sử dụng ChunkFormer làm mô hình benchmark độ chính xác trong ngắn hạn, đồng thời fine-tune PhoWhisper-medium như một hướng cân bằng giữa tốc độ, khả năng triển khai và chất lượng. Mọi output ASR cần đi qua lớp kiểm tra an toàn hậu xử lý và bác sĩ xác nhận trước khi được dùng cho clinical fact extraction hoặc SOAP note generation.

12 Phụ lục — Giả định

1. Tất cả số liệu WER/CER được lấy từ kết quả thực nghiệm trong repository dự án.
2. Runtime được ghi nhận trong môi trường GPU T4 hoặc môi trường tương đương, nên có thể thay đổi khi triển khai local.
3. Tập dev được dùng cho model selection; test_holdout chưa được dùng để điều chỉnh mô hình.
4. Phân tích lỗi y khoa dựa trên từ điển kiểm tra hiện có, chưa thay thế được review của bác sĩ.

PHẦN II: BÁO CÁO KỸ THUẬT TIỀN XỬ LÝ ÂM THANH

1 Tóm tắt Điều hành

1.1 Mục tiêu báo cáo

Báo cáo này được xây dựng nhằm mục đích:

- Xác nhận vấn đề mất tín hiệu âm thanh ở đầu/cuối (Edge Loss) trong tập dữ liệu VietMed.
- Trình bày kết quả đánh giá (Ablation) các phương án tiền xử lý âm thanh để giải quyết lỗi trên.
- Giải thích lý luận chiến lược MLOps trong việc chọn mô hình và loại bỏ các kỹ thuật tiền xử lý không phù hợp.

1.2 Kết luận nổi bật

Bảng 12: Tóm tắt kết quả kỹ thuật

Hạng mục	Kết luận
Vấn đề cốt lõi	Nguy cơ mất từ (edge loss) chiếm 18.3% (Train) và 14.5% (Dev), là nguyên nhân chính gây hụt transcript ở ranh giới câu.
Giải pháp thành công	Kỹ thuật VAD + 200ms Padding (p03_vad_pad_200ms) cải thiện Edge-risk WER từ 12.18% xuống 11.81%, duy trì WER tổng 12.90%.
Giải pháp thất bại	Kỹ thuật Padding-only (p10) làm WER tệ đi (tăng lên 14.49%).
Mô hình thực nghiệm	ChunkFormer được dùng làm baseline proxy duy nhất vì có WER tốt nhất (12.90%).
Quyết định tiếp theo	Chốt áp dụng p03_vad_pad_200ms cho toàn bộ tập Train trước khi bước vào giai đoạn Fine-tuning.

2 Hiện trạng Chất lượng Âm thanh và Lỗi Edge Loss

2.1 Khảo sát chất lượng ban đầu (Audio QA)

Kiểm tra tự động trên tập dữ liệu gốc VietMed (Day 1) cho thấy một vấn đề nghiêm trọng liên quan đến ranh giới âm thanh:

- Tập Train (600 mẫu):** Có 110 mẫu (18.3%) bị đánh dấu cảnh báo `edge_loss_risk`.

- **Tập Dev (200 mẫu):** Có 29 mẫu (14.5%) bị đánh dấu cảnh báo `edge_loss_risk`.

Năng lượng âm thanh ở ranh giới đầu/cuối quá yếu. Nếu đưa trực tiếp vào mô hình, ASR có nguy cơ cao sẽ bỏ sót các từ đầu và cuối câu do cửa sổ trích xuất đặc trưng (feature extraction window) không đủ bối cảnh (context).

2.2 Tình trạng Âm lượng (Loudness)

Đáng chú ý, các vấn đề về âm lượng tổng thể hoàn toàn không tồn tại. Kết quả ghi nhận ****0 file**** gặp lỗi `too_quiet`, `too_loud`, hay `clipping_risk`. Chỉ số RMS (năng lượng trung bình) nằm ở mức chuẩn ~ -23.5 dB và Peak (đỉnh) ở mức ~ -4.6 dB. Điều này cho thấy chất lượng thu âm rất "khỏe mạnh".

2.3 Chuẩn hóa Định dạng Âm thanh (16kHz Mono PCM)

Toàn bộ tập dữ liệu đã được xác nhận tuân thủ chuẩn định dạng **16kHz mono PCM (WAV)** từ trước khi bước vào thực nghiệm. Báo cáo kiểm toán chất lượng (QA Audit) ghi nhận tuyệt đối ****0 lỗi**** `non_16khz` và `non_mono`. Quá trình chuyển đổi định dạng này đã được thực hiện khi đưa dữ liệu từ tầng Bronze (thô) sang tầng Silver (chuẩn hóa), đảm bảo tính đồng nhất 100% cho đầu vào của các mô hình ASR.

3 Đánh giá Thực nghiệm Tiền xử lý (Ablation Study)

Để khắc phục lỗi Edge Loss, đội ngũ đã tạo các biến thể tiền xử lý và chạy thực nghiệm (A/B testing) trực tiếp trên mô hình ChunkFormer.

3.1 Định nghĩa các biến thể (Preprocessing Variants)

Để người đọc dễ dàng đối chiếu, dưới đây là định nghĩa chi tiết về cơ chế hoạt động của các biến thể được sử dụng:

- **original:** Âm thanh gốc đã được chuẩn hóa 16kHz mono PCM ở tầng Silver, chưa qua bất kỳ can thiệp cắt ghép hay bù đắp nào.
- **p10_edge_pad_200ms** (Padding-only): Kỹ thuật chèn cơ học 200ms khoảng lặng (silence) trực tiếp vào ranh giới hai đầu của file. Nhược điểm là thuật toán này mù quáng, không biết vị trí thực sự của tiếng nói nằm ở đâu.
- **p03_vad_pad_200ms** (VAD + Padding): Kỹ thuật kết hợp sử dụng Voice Activity Detection (VAD) để định vị chính xác khoảng thời gian con người thực sự phát âm, sau đó mới chèn thêm 200ms khoảng lặng từ ranh giới phát âm đó trở ra để bảo vệ các âm tiết đầu/cuối không bị lẹm.

3.2 Kết quả Leaderboard (Tập Dev)

3.3 Nhận định Thành tựu

Việc thử nghiệm không chỉ dừng ở mức lên kế hoạch mà đã nghiệm thu thành công bằng các chỉ số thực tế:

Bảng 13: Kết quả chạy ChunkFormer trên các biến thể tiền xử lý

Biến thể	Mô hình	Strict WER	Medical Errors	Edge-risk WER	Quyết định
original	ChunkFormer	12.90%	7	12.18%	Baseline tham chiếu
p10_edge_pad_200ms	ChunkFormer	14.49%	6	13.49%	Loại bỏ (Làm tăng WER)
p03_vad_pad_200ms	ChunkFormer	12.90%	7	11.81%	Được chọn (Cải thiện Edge WER)

- **Loại bỏ phương án sai lầm:** Việc chêm khoảng lặng ngây thơ (Padding-only/p10) khiến mô hình bị nhiễu, làm độ chính xác giảm sút (WER tăng vọt).
- **Chứng minh hiệu quả:** Phương án kết hợp VAD để tìm đúng ranh giới tiếng nói rồi mới Padding (p03) đã thành công giảm tỷ lệ lỗi trên tập con rủi ro (Edge-risk subset) từ 12.18% xuống 11.81%, trong khi không làm tăng các lỗi y khoa nghiêm trọng.

4 Chiến lược Lựa chọn Mô hình Thực nghiệm

4.1 Danh mục các mô hình hiện có

Hệ thống dự án hiện đang sở hữu tổng cộng **5 mô hình** bên cạnh ChunkFormer:

1. vinai/PhoWhisper-medium
2. vinai/PhoWhisper-base
3. openai/whisper-small
4. ViStreamASR (Adapter)
5. Zipformer-30M-RNNT (Adapter)

4.2 Lý do chỉ dùng ChunkFormer cho Ablation Study

Trong quy trình MLOps, thử nghiệm A/B Testing trên dữ liệu rất tốn kém tài nguyên ($O(N_{models} \times M_{variants})$). Chiến lược tối ưu là sử dụng mô hình có hiệu năng cao nhất làm "thước đo" (proxy):

- ChunkFormer là mô hình chính xác nhất hiện tại (WER 12.90%), vượt xa PhoWhisper-medium (21.51%).
- Một mô hình nhạy bén và độ chính xác cao sẽ phản ánh chân thực nhất sự thay đổi chất lượng của dữ liệu (Data Quality).
- Nếu thử nghiệm trên các mô hình kém hơn (như Whisper-small với WER 53%), các lỗi do bản thân kiến trúc mô hình dở sẽ lấn át (masking) lợi ích của việc sửa dữ liệu, làm sai lệch quyết định.

5 Lý luận Kỹ thuật: Các Phương án Bị Loại bỏ

Trong quá trình thiết kế giải pháp tiền xử lý, nhiều phương án đã được đưa ra nhưng bị loại trừ. Dưới đây là lý luận kỹ thuật (Rationale) xác đáng cho các quyết định này:

Bảng 14: Lý do từ chối các phương án tiền xử lý thay thế

Phương pháp	Trạng thái	Lý do Kỹ thuật & Lâm sàng
Padding-only	Đã thử và loại	Thực nghiệm biến thể p10 chứng minh việc chèn thêm khoảng lặng mù quáng mà không phân tích âm thanh sẽ làm tăng WER lên 14.49%.
VAD-only	Từ chối	VAD có chức năng cắt vứt khoảng lặng. Dữ liệu gốc đang bị lỗi lẹm từ (Edge loss). Việc dùng VAD-only sẽ gọt âm thanh chặt hơn, làm trầm trọng thêm sự hụt tiếng ở ranh giới.
Chunk Overlap	Từ chối	Phương pháp này sinh ra cho các luồng audio dài (hàng chục phút) phải bấm nhỏ để tránh cắt đôi từ giữa các chunk. Audio y khoa hiện tại rất ngắn (trung bình 6 giây), mất chữ ở 2 đầu gốc chứ không phải ở ranh giới chunk. Chèn overlap là áp dụng sai use-case.
Noise Reduction	Từ chối	Báo cáo QA Ngày 1 xác nhận không có vấn đề tiếng ồn/tạp âm. Với y khoa, bộ lọc nhiễu mang rủi ro chí mạng: nó có thể xóa sổ các âm thanh quan trọng có tần số thấp (tiếng thở ran, tiếng ho, hoặc lời nói lí nhí), làm mất dữ liệu chẩn đoán.
Amplitude Normalization	Từ chối	Âm lượng gốc đang ở ngưỡng cực kỳ lý tưởng ($\text{RMS} \sim -23.5 \text{ dB}$, $\text{Peak} \sim -4.6 \text{ dB}$). Việc ép chuẩn hóa biên độ (dùng AGC/Compressor) sẽ tạo hiệu ứng "Noise pumping" (khuếch đại rác ở các khoảng lặng) và làm biến dạng tính tự nhiên trong sắc thái giọng nói lâm sàng. Không sửa thứ không hỏng.

6 Kết luận

Thực nghiệm tiền xử lý (Preprocessing Ablation) không chỉ là một kế hoạch trên giấy mà đã được chứng minh thành công qua dữ liệu. Phương pháp **VAD + 200ms Padding** (p03_vad_pad_200ms) đã giải quyết được nút thắt cổ chai "Edge Loss" một cách hiệu quả, an toàn, và được bảo chứng qua kết quả trên mô hình tốt nhất là ChunkFormer.

Mọi quyết định từ bỏ các phương pháp thừa thãi (như Noise Reduction hay Normalization) đều tuân thủ chặt chẽ nguyên lý: Chỉ giải quyết đúng điểm nghẽn dựa trên bằng chứng dữ liệu kiểm toán (Audio QA), bảo vệ tối đa tính nguyên bản của âm thanh lâm sàng. Bước tiếp theo của dự án là tự tin áp dụng pipeline này lên toàn bộ tập dữ liệu huấn luyện để sẵn sàng cho Phase Fine-tuning.

PHẦN III: CÁC CẬP NHẬT MỚI VÀ SẴN SÀNG FINE-TUNING

1 Đánh giá Thủ công (Manual Inspection) và Chiến lược Safe Hybrid

1.1 Phát hiện rủi ro từ VAD

Mặc dù phương án `p03_vad_pad_200ms` giúp cải thiện Edge-risk WER, đội ngũ đã tiến hành kiểm tra thủ công (Manual Inspection) một tập hợp các file được phân loại là "VAD-risky" (những file có nguy cơ thuật toán Voice Activity Detection cắt nhầm vào tiếng nói).

Kết quả kiểm tra chi tiết các mẫu như `public_vietmed_0007`, `public_vietmed_0152`, và `public_vietmed_0894` cho thấy:

- Một số từ ở cuối câu bị cắt lẹm (ví dụ: mất từ "nhưng", hoặc mất cụm "ngày được phát vào").
- Một số từ ở đầu câu bị lẹm (ví dụ: mất từ "hiểu").
- Tuy nhiên, thuật toán VAD cũng giúp loại bỏ rất hiệu quả các khoảng thở tự nhiên, âm "xoẹt" hoặc khoảng lặng dư thừa.

1.2 Chiến lược Safe Hybrid (`p03_safe_hybrid_v0_1`)

Để giải quyết dứt điểm sự đánh đổi này, hệ thống không áp dụng `p03` một cách mù quáng cho 100% tập dữ liệu, mà triển khai mô hình **Safe Hybrid**:

- Các file thông thường sẽ áp dụng `p03_vad_pad_200ms` để tối ưu hóa ranh giới và loại bỏ khoảng lặng/thở.
- Các file được phát hiện có rủi ro VAD cắt mất chữ sẽ tự động fallback (quay về) sử dụng âm thanh gốc (`original.wav`).

Nhờ chiến lược này, chất lượng âm thanh được đưa về mức an toàn tối đa. Báo cáo chất lượng (Padding-Aware) cuối cùng ghi nhận:

- **Tập Train (600 mẫu):** Chỉ còn 30 mẫu có rủi ro Speech Edge Loss (5.0%).
- **Tập Dev (200 mẫu):** Chỉ còn 11 mẫu có rủi ro Speech Edge Loss (5.5%).

Các file manifest dữ liệu cuối cùng được chốt hạ là `vietmed_train_preprocessed_selected_safe_v0_1` và `vietmed_dev_preprocessed_selected_safe_v0_1.jsonl`.

2 Chuẩn hóa Quy trình End-to-End và Tái Cấu trúc Dự án

2.1 Tài liệu hóa 10-step ASR Benchmark Pipeline

Nhằm đảm bảo tính tái lập (reproducibility) tuyệt đối cho bất kỳ kỹ sư nào tham gia dự án, toàn bộ quy trình ASR Benchmark đã được tài liệu hóa thành sổ tay `RUN_BENCHMARK.md`. Quy trình bao gồm 10 bước chuẩn MLOps:

1. Thiết lập môi trường (`source .venv`).
2. Ingestion dữ liệu thô (vào Bronze layer).
3. Chuẩn hóa âm thanh 16kHz Mono (vào Silver layer).
4. Phân chia tập dữ liệu (Train/Dev/Test splits).
5. Kiểm tra rò rỉ dữ liệu (Check Leakage).
6. Đánh giá mô hình PhoWhisper.
7. Đánh giá mô hình ChunkFormer.
8. Tính toán chỉ số WER/CER (Sử dụng protocol chuẩn hóa chữ/số).
9. Phân tích lỗi y khoa (Medical Error Analysis).
10. Xuất báo cáo tổng hợp cuối cùng.

2.2 Tái cấu trúc thư mục Notebooks

Đội ngũ đã dọn dẹp thư mục gốc và quy hoạch toàn bộ các tệp Jupyter Notebook (chạy nhập, visualization) vào thư mục `notebooks/`. Cấu trúc này cùng với việc cập nhật `README.md` sang kiến trúc phân kỳ (phase-based) giúp codebase trở nên gọn gàng, giảm technical debt và sẵn sàng cho các pha phát triển mở rộng.

3 Sẵn sàng cho Giai đoạn Fine-tuning

Sau khi hoàn tất cả hai công tác chuẩn bị lớn là Benchmark mô hình và Xử lý dữ liệu âm thanh, dự án chính thức đạt trạng thái **Sẵn sàng Fine-tuning (Fine-tune Readiness)** với các thông số sau:

Guardrails (Quy tắc an toàn MLOps): Không huấn luyện trên tập dev; tuyệt đối không huấn luyện trên tập test_holdout; không sử dụng tập test_holdout để lựa chọn checkpoint tốt nhất; và giữ nguyên giao thức tính toán WER hiện tại để đảm bảo tính so sánh xuyên suốt.

Bảng 15: Cấu hình dữ liệu và mô hình cho Giai đoạn Fine-tuning

Hạng mục	Chi tiết
Dữ liệu Train	600 mẫu, Manifest: vietmed_train_preprocessed_ selected_safe_v0_1.jsonl
Dữ liệu Dev	200 mẫu, Manifest: vietmed_dev_preprocessed_ selected_safe_v0_1.jsonl
Dữ liệu Test Holdout	200 mẫu gốc, hoàn toàn cách ly, không được dùng để chọn mô hình.
Mô hình Baseline (tham chiếu)	khanhld/ chunkformer-ctc-large-vie
Ứng viên Fine-tuning số 1	vinai/ PhoWhisper-medium
Mục tiêu trọng tâm	Giảm thiểu các lỗi đặc thù y khoa: bỏ sót phủ định, sai liều lượng/thuốc, và cải thiện tỷ lệ nhận dạng ở các mẫu có rủi ro biên (edge-risk).